文献问答质量评测 · 阶段汇报

已完成32题、六维度的双模型评分基线；具备逐题追溯、分歧定位和原文核查能力，为后续RAG优化提供可比较的依据。

一、已经完成的工作

- 建立题目、参考答案、必答要点、数值容差及关键错误规则；覆盖事实、数值、比较、机理、证据不足和错误前提等问题。
- 对同一批原始RAG回答独立评分：Luna与最新Jev统一六个维度；请求、证据、评分、费用均留档，并生成32题完整HTML报告。

二、同一批32题的评测结果

评分维度	Luna	Jev（最新轮次）
必答要点完整性（逐题宏平均）	89.06%	88.54%
陈述获得完整支持（含范围声明）	122/126（96.83%）	122/126（96.83%）
单条事实引用有效	123/123（100.00%）	125/125（100.00%）
事实陈述的引用组完整	109/116（93.97%）	113/118（95.76%）
证据边界判断（满分2）	1.8125	1.6875
检索充分性（完整 / 部分 / 缺失）	68 / 4 / 5	63 / 9 / 5

注：以上是裁判标签统计，不是准确率；检索含77个适用要点，另11个不适用。不同维度不相加成一个总分。

三、主要发现与质量判断

- 前四维度达标：Luna 19/32、Jev 21/32；进一步要求边界满分后，双方均为19/32。要点总体较完整，完整达标仍有提升空间。
- 要点评分一致率93.90%，边界判断87.50%，检索判断89.61%；18/32题至少一项标签不同，需按原文复核，不能把一致率当作正确率。

四、当前不足与下一步

当前不足

仅1篇论文、32道开发题，缺少独立专家金标准；最新Jev只有1轮，尚不能说明稳定性和跨论文泛化。

下一步工作

优先复核分歧题及一致样本；扩充论文与评测题，再比较检索、证据组织和回答边界的优化效果。

本轮Jev：32次有效调用，无补评；API报告费用 $0.0972，单题请求中位耗时0.916秒。Luna复用既有评分，本轮无新增调用。

依据：最新六维度对照记录与32题HTML明细；原回答保持冻结。本页整理未新增模型调用。